



Matemáticas para ciencia de datos

Olivia Gutú

Semana 4

Descomposición en valores singulares y análisis en componentes principales

Descomposición en valores singulares

SVD

Toda matriz (real) tiene la forma:

$$A = U\Sigma V^T$$

U y V son matrices ortogonales y Σ matriz diagonal de valores singulares

SVD y Teorema espectral

La SVD existe para *cualquier matriz*: ¡no tiene que ser cuadrada!

SVD: idea principal

Sea A una matriz de $m \times n$. La idea es (1) encontrar (recordar que $\text{rank } A = \text{rank } A^T$):

- ▶ un conjunto ortonormal de vectores $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ de $\text{im}(A^T)$
- ▶ un conjunto ortonormal de vectores $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_r$ de $\text{im}(A)$

tal que:

$$\begin{aligned} A(\mathbf{v}_1 \ \mathbf{v}_2 \ \cdots \ \mathbf{v}_r) &= (\sigma_1 \mathbf{u}_1 \ \sigma_2 \mathbf{u}_2 \ \cdots \ \sigma_r \mathbf{u}_r) \\ &= (\mathbf{u}_1 \ \mathbf{u}_2 \ \cdots \ \mathbf{u}_r) \begin{pmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \ddots & \\ & & & \sigma_r \end{pmatrix} \end{aligned}$$

con

$$\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$$

SVD: idea principal

(2) completar las bases de $\text{im}(A^T)$ con el $\text{ker}(A)$ y $\text{im}(A)$ con el $\text{ker}(A^T)$ (se completa la matriz diagonal con ceros). (1) y (2) implican $AV = U\Sigma$:

$$\begin{aligned} V &= (v_1 \ v_2 \ \cdots \ v_r \ v_{r+1} \ \cdots \ v_n) \\ U &= (u_1 \ u_2 \ \cdots \ u_r \ u_{r+1} \ \cdots \ u_m) \\ \Sigma &= \left(\begin{array}{cccc|c} \sigma_1 & & & & 0 \\ & \sigma_2 & & & \\ & & \ddots & & \\ & & & \sigma_r & \\ \hline & & & & 0 \end{array} \right) \end{aligned}$$

por tanto:

$$A = U\Sigma V^T$$

SVD: ¿cómo funciona?

Notar que:

$$\text{rank } A^T A = \text{rank } A A^T = \text{rank } A = \text{rank } A^T$$

y

el rango de la matriz $A^T A$ es el número de autovalores distintos de cero (contando multiplicidad)

SVD: ¿cómo funciona?

- ▶ $\lambda_1, \lambda_2 \dots \lambda_r$ autovalores diferentes de cero de $A^T A$
- ▶ $v_1, v_2, \dots v_r$ conjunto ortonormal de autovectores de $A^T A$ correspondientes a los autovalores diferentes de cero.

$$\sigma_i := \sqrt{\lambda_i} \quad \text{la raíz positiva}$$

Esto existe por el teorema espectral ya que $A^T A$ es simétrica.

SVD: ¿cómo funciona?

Para $i = 1, 2, \dots, r$:

- ▶ se tiene $A^T A v_i = \sigma_i^2 v_i$
- ▶ notar que v_i está en $\text{im}(A^T)$
- ▶ se define $u_i := \frac{A v_i}{\sigma_i}$ (luego $A A^T u_i = \sigma_i^2 u_i$ y por tanto u_i está en $\text{im}(A)$)
- ▶ se cumple $u_i \cdot u_j = 0$ si $i \neq j$ y $u_i \cdot u_i = 1$

Después:

- ▶ completamos los últimos $n - r$ vectores v_{r+1} a v_n
- ▶ completamos los últimos $m - r$ vectores u_{r+1} a u_m
- ▶ los nuevos vectores pertenecen al $\ker A$ y $\ker A^T$, respectivamente

Forma reducida de la SVD

El corazón de la SVD es $AV_r = U_r \Sigma_r$:

$$A \begin{pmatrix} \mathbf{v}_1 & \cdots & \mathbf{v}_r \\ \text{base del espacio} \\ \text{renglón de A} \end{pmatrix} = \begin{pmatrix} \mathbf{u}_1 & \cdots & \mathbf{u}_r \\ \text{base del espacio} \\ \text{columna de A} \end{pmatrix} \begin{pmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \ddots & \\ & & & \sigma_r \end{pmatrix}$$

$$\text{im} A^T = \text{span}\{\text{renglones de } A\}$$

$$\text{im} A = \text{span}\{\text{columnas de } A\}$$

Dato importante para los científicos de datos

La matriz de rango k

$$A_k := \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \cdots + \sigma_k \mathbf{u}_k \mathbf{v}_k^T$$

es la que *mejor aproxima* a A con rango k :

Eckart-Young

Si B es una matriz de rango k entonces

$$\|A - A_k\| \leq \|A - B\|.$$

Dato importante para los científicos de datos

Norma espectral $\|A\|_2 = \max \frac{\|Ax\|}{\|x\|} = \sigma_1$

Norma de Frobenius $\|A\|_F = \sqrt{\sigma_1^2 + \cdots \sigma_r^2}$

Norma nuclear $\|A\|_N = \sigma_1 + \sigma_2 + \cdots + \sigma_r$

Análisis en componentes principales (PCA)

PCA resulta de aplicar la SVD a una matriz A_{centered} de datos centrada con n columnas (*variables*) y m renglones (*samples*)

Componentes principales

$$\sigma_1 u_1, \sigma_2 u_2, \dots, \sigma_r u_r \in \mathbb{R}^m$$

Análisis en componentes principales (PCA)

Variación total

$$T = \frac{\sigma_1^2 + \cdots + \sigma_r^2}{m - 1}$$

Los σ_i^2 son los autovalores distintos de cero de la matriz de covarianza

$$A_{\text{centered}}^T A_{\text{centered}}$$

La componente principal $\sigma_i u_i$ explica la fracción σ_i^2 / T de la variación total. Cada valor singular hace su mejor captura: σ_1 explica más que σ_2 y así sucesivamente.